

Deploy en la nube – Oracle Cloud Infrastructure (OCI)

Introducción

Una vez finalizado el desarrollo y las pruebas del agente conversacional basado en la arquitectura **Retrieval-Augmented Generation (RAG)**, el siguiente paso consiste en realizar el despliegue de la aplicación en un entorno de nube. El objetivo es que el sistema deje de ejecutarse únicamente en el equipo del desarrollador y pueda ser utilizado por todos los colaboradores de BimBam Buy mediante una interfaz web.

Para este proyecto se propone utilizar **Oracle Cloud Infrastructure (OCI)**, una plataforma que ofrece servicios de infraestructura, almacenamiento, seguridad y administración, permitiendo ejecutar la aplicación de forma segura, escalable y centralizada.

Objetivo del despliegue

El despliegue tiene como finalidad poner el agente de IA en funcionamiento dentro de una infraestructura en la nube, permitiendo que cualquier colaborador autorizado pueda acceder al sistema desde un navegador web.


Al centralizar la aplicación en OCI se obtienen beneficios como:

- Disponibilidad permanente.
- Acceso remoto desde cualquier ubicación.
- Mayor seguridad de la información.
- Facilidad para actualizar documentos y código.
- Escalabilidad para soportar un mayor número de usuarios.

Arquitectura propuesta

La solución desarrollada está compuesta por una interfaz web en Streamlit, un motor RAG implementado en Python, una base vectorial ChromaDB y el modelo de lenguaje Gemini 2.5 Flash.

La arquitectura propuesta para el despliegue en Oracle Cloud Infrastructure es la siguiente:



Componentes de la solución

Usuario

El colaborador realiza una consulta utilizando la interfaz desarrollada en Streamlit desde cualquier navegador web.

Aplicación Streamlit

La aplicación web recibe la pregunta del usuario y muestra la respuesta generada por el agente junto con los documentos utilizados como fuente de información.

Esta interfaz fue desarrollada en Python mediante Streamlit debido a su facilidad de implementación y rapidez para crear aplicaciones interactivas.

Motor RAG

El archivo **rag.py** implementa toda la lógica del sistema.

Su funcionamiento consiste en:

- recibir la consulta del usuario;
- buscar información relevante en la base vectorial;
- construir el contexto;
- enviar dicho contexto al modelo Gemini;
- devolver la respuesta junto con las fuentes consultadas.

ChromaDB

ChromaDB almacena los embeddings generados a partir de los documentos PDF.

Cuando el usuario realiza una consulta, se ejecuta una búsqueda semántica para recuperar los fragmentos más relacionados con la pregunta.

De esta forma el modelo responde utilizando únicamente información existente en la documentación corporativa.

Gemini 2.5 Flash

Gemini recibe el contexto recuperado por ChromaDB y genera la respuesta final.

Gracias al prompt diseñado durante el desarrollo del proyecto, el modelo únicamente responde utilizando la información presente en los documentos indexados.

Si la información no existe, responde indicando que no fue encontrada.

Servicios de Oracle Cloud Infrastructure utilizados

OCI Compute

El servicio **OCI Compute** se utiliza para alojar la aplicación desarrollada en Python.

En esta instancia se ejecutan:

- Streamlit.
- rag.py.
- Base vectorial ChromaDB.
- Dependencias del proyecto.

Este servicio mantiene la aplicación disponible para todos los usuarios.

OCI Object Storage

Todos los documentos utilizados por el agente se almacenan en **OCI Object Storage**.

Entre ellos:

- Programa de Afiliados.
- Política de Reembolsos y Devoluciones.
- Guía de Tiempos y Costos de Envío.
- Manuales internos.
- Documentación corporativa.

Este servicio proporciona almacenamiento seguro, alta disponibilidad y facilidad para actualizar la documentación.

Resumen del diagrama

La arquitectura propuesta muestra el flujo completo de funcionamiento del agente de IA desplegado en Oracle Cloud Infrastructure.

El usuario accede mediante una interfaz web desarrollada con Streamlit. La aplicación procesa la consulta utilizando la lógica implementada en rag.py, que recupera los fragmentos de texto más relevantes desde ChromaDB. Posteriormente, el contexto obtenido es enviado al modelo Gemini 2.5 Flash para generar una respuesta fundamentada exclusivamente en la documentación corporativa almacenada en OCI Object Storage. Finalmente, la respuesta y las fuentes utilizadas son presentadas al usuario.

OCI Vault

Las credenciales utilizadas por el sistema, especialmente la API Key de Gemini, se almacenan mediante **OCI Vault**.

De esta forma la información sensible no queda expuesta dentro del código fuente ni del repositorio GitHub.

[Flujo de funcionamiento](#)

El funcionamiento de la aplicación desplegada es el siguiente:

1. El usuario accede a la aplicación mediante un navegador web.
2. Streamlit recibe la consulta.
3. La función preguntar () ejecuta una búsqueda semántica en ChromaDB.
4. Se recuperan los fragmentos más relevantes de los documentos.
5. Se construye un contexto utilizando únicamente dichos fragmentos.
6. El contexto es enviado al modelo Gemini.
7. Gemini genera una respuesta fundamentada exclusivamente en la información recuperada.
8. La aplicación muestra la respuesta junto con las fuentes consultadas.

Seguridad

Durante el despliegue se consideran las siguientes medidas de seguridad:

- almacenamiento seguro de credenciales mediante OCI Vault;
- documentos protegidos en OCI Object Storage;
- acceso controlado mediante las políticas de seguridad de Oracle Cloud;
- aislamiento de la aplicación dentro de una instancia OCI Compute;
- reducción del riesgo de respuestas incorrectas gracias a la arquitectura RAG.

Beneficios del despliegue

La utilización de Oracle Cloud Infrastructure aporta diversas ventajas:

- acceso centralizado para todos los colaboradores;
- disponibilidad permanente del sistema;
- facilidad para actualizar documentación;
- mayor seguridad en el manejo de información;
- posibilidad de escalar la solución según aumente la cantidad de usuarios;
- mantenimiento simplificado de la aplicación.

Integración con GitHub

El código fuente del proyecto se almacena en un repositorio GitHub.

Esto permite:

- mantener el control de versiones;
- facilitar el trabajo colaborativo;
- registrar cada modificación realizada durante el desarrollo;
- servir como base para futuras actualizaciones.

En un entorno de producción, el repositorio podría integrarse con un pipeline de CI/CD para automatizar el despliegue de nuevas versiones hacia Oracle Cloud Infrastructure.

Resultado esperado

Mediante el despliegue propuesto en Oracle Cloud Infrastructure, el agente conversacional desarrollado para BimBam Buy queda preparado para ser utilizado por todos los colaboradores de la organización.

La combinación de Streamlit, Python, ChromaDB y Gemini permite responder consultas utilizando únicamente la información almacenada en los documentos corporativos, mostrando siempre las fuentes utilizadas. La infraestructura propuesta en OCI aporta disponibilidad, seguridad, escalabilidad y facilita el mantenimiento futuro del sistema.

Evidencias del funcionamiento

Para validar el correcto funcionamiento del sistema se realizaron distintas pruebas durante el desarrollo.

Prueba 1 – Consulta sobre Programa de Afiliados

Pregunta

¿Cómo funciona el programa de afiliados?

Resultado

El agente recuperó correctamente la información desde el documento **Programa de Afiliados de BimBam Buy.pdf**, generando una respuesta coherente y mostrando las fuentes consultadas.

¿Cómo funciona el programa de afiliados?

👉 **BimBam Buy AI**

El programa de afiliados funciona de la siguiente manera:

El afiliado recibe un enlace o código rastreable. Cuando una compra válida se origina desde ese canal, la venta puede generar comisión, siempre que:

- * El pedido sea confirmado
- * No exista anulación fraudulenta
- * El pago sea aprobado
- * La compra cumpla condiciones de atribución

El funcionamiento general se apoya en seguimiento técnico, validación interna y reglas de conversión previamente definidas por BimBam Buy.

Figura 1. Respuesta del agente sobre el Programa de Afiliados.

Prueba 2 – Consulta sobre Devoluciones

Pregunta

¿Cuáles son las condiciones para aceptar una devolución?

Resultado

El sistema recuperó correctamente la información desde la **Política de Reembolsos y Devoluciones**, respondiendo únicamente con la información disponible en el documento.

¿Cuáles son las condiciones para aceptar una devolución?

☺ **BimBam Buy AI**

Para que una devolución sea aceptada, el producto debe cumplir con lo siguiente:

- * Contar con comprobante de compra o número de orden
- * Presentarse dentro del plazo aplicable
- * Estar completo, con accesorios, manuales y obsequios promocionales si los hubiera
- * No mostrar señales de uso incompatibles con la revisión solicitada
- * Mantener, cuando corresponda, empaque original o protección equivalente
- * No haber sido sometido a reparación externa no autorizada

Además, el equipo de soporte podrá verificar:

- * Coincidencia entre el producto recibido y el declarado por el cliente
- * Estado visible del artículo
- * Condiciones de embalaje
- * Integridad de sellos o etiquetas cuando aplique
- * Coherencia entre

Figura 2. Respuesta del agente sobre la política de devoluciones.

Prueba 3 – Consulta fuera del dominio

Pregunta

¿Cuál es la capital de Francia?

Resultado esperado

No encontré esa información en los documentos disponibles.

Esta prueba demuestra que el agente no genera respuestas inventadas cuando la información solicitada no se encuentra dentro de la base documental.

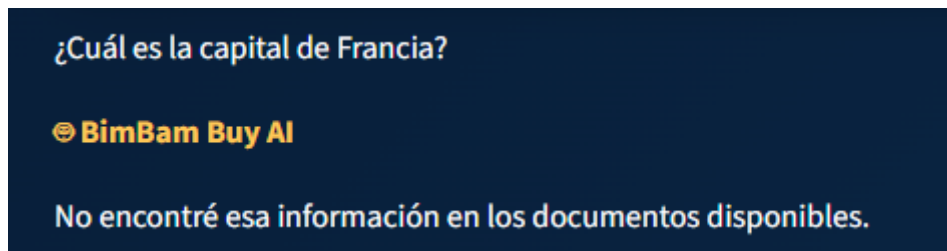


Figura 3. Consulta sin información disponible.

Posibles mejoras futuras

Aunque el sistema cumple con los objetivos planteados, existen diversas mejoras que podrían incorporarse en futuras versiones:

- Automatizar la actualización de documentos mediante un pipeline conectado a OCI Object Storage.
- Implementar integración con Microsoft Teams o Slack para facilitar el acceso de los colaboradores.
- Incorporar autenticación de usuarios mediante Oracle Identity and Access Management (IAM).
- Sustituir ChromaDB por Oracle Autonomous Database con búsqueda vectorial para un entorno de producción.
- Implementar un pipeline CI/CD utilizando GitHub Actions u OCI DevOps para automatizar las actualizaciones del sistema.
- Incorporar métricas de uso, tiempos de respuesta y feedback de los usuarios para mejorar continuamente el agente.

Conclusión del despliegue

El despliegue propuesto demuestra que el agente conversacional desarrollado para BimBam Buy puede ejecutarse en un entorno cloud moderno, seguro y escalable utilizando Oracle Cloud Infrastructure. La arquitectura planteada permite centralizar la aplicación, proteger la información sensible, almacenar de forma segura la documentación corporativa y ofrecer respuestas fundamentadas mediante la combinación de ChromaDB y Gemini 2.5 Flash.

La utilización de servicios como **OCI Compute**, **OCI Object Storage** y **OCI Vault** proporciona una base sólida para una futura implementación en producción, permitiendo que el agente pueda crecer junto con las necesidades de la organización.